




ماشین‌های بردار پشتیبان



دانشگاه شهید بهشتی
پژوهشکده‌ی فضای مجازی
پاییز ۱۴۰۳
احمد محمودی ازناوه

فهرست مطالب

- ماشین بردار پشتیبان (SVM)
 - تاریخچه
 - داده‌های جدایی‌پذیر خطی
 - Hard Margin
 - Soft Margin
 - مجموعه‌های جدایی‌ناپذیر خطی
 - نگاشت به فضایی با ابعاد بالا
 - ترغند استفاده از کرنل (تابع هسته)
- SVR
- مواجهه با مجموعه داده‌های imbalanced




تاریخچه


- نسخه‌ی اولیه‌ی SVM توسط آقای Vladimir Vapnik ارائه شد.
- Vapnik با همکاری خانم Corinna Cortes استاندارد کنونی SVM را در سال ۱۹۹۳ پایه‌ریزی کرده و در سال ۱۹۹۵ منتشر نمودند.



Cortes, C. and V. Vapnik (1995). "Support-vector networks." Machine Learning 20(3): 273-297.



- یک جداکننده خطی را می‌توان همانند شکل زیر در نظر گرفت.





$$F(X) = \text{SIGN}(W^T X + b)$$



مرز بهینه

• سوال


– کدام یک از مرزها، مرزی بهینه برای جداسازی است؟



مرز جداسازی

- می‌خواهیم به گونه‌ای بهترین مرز جداسازی را به دست آوریم.

Margin of separation





فرض کنیم نزدیک‌ترین نقطه به مرز جداسازی در نظر گرفته شده و فاصله را r بنامیم.

هدف ما کنیم نمودن r است.

یک ماشین به مشخص می‌کنیم هر مرزی که ماشین به پهن‌تری را نتیجه دهد، بهتر است.


دانشگاه
شهید
بهشتی

مرز بهینه




ماشیهی ماکزیمم

- ماکزیمم نمودن ماشیه (Margin) ایدهی خوبی است جهت جداسازی خطی، این شیوه را **LSVM** یا **Linear SVM** می‌نامند.
- در این حالت نمونه‌هایی که به روی مرز ماشیه هستند، از اهمیت ویژه‌ای برخوردارند.
- بدین وسیله می‌توان از نمونه‌های دیگر صرف‌نظر کرد و تنها به نمونه‌های مهم روی مرز ماشیه پرداخت.




- به نمونه‌های روی مرز ماشیه «بردار پشتیبان» می‌گویند.



بردارهای پشتیبان

Optimal hyperplane



مرز جداسازی

- برای معادله‌ی مرز جداسازی داشتیم:

$$W^T X + b = 0$$

$$(X_i, d_i = +1) \quad W^T X_i + b > 0$$


$$(X_i, d_i = -1) \quad W^T X_i + b < 0$$

- فرض کنیم مرز بهینه توسط W_{op} و b_{op} مشخص شود.

- اگر نزدیک‌ترین نقطه به مرز جداسازی را در نظر گرفته، فاصله را « r » بنامیم.

- هدف

– ماکزیمم نمودن فاصله یا همان $\rho = 2r$ است.




مرز جداسازی (ادامه...)

- در صورتی که X بردار پشتیبان باشد، طبق شکل زیر خواهیم داشت:


$$X = X_p + \overrightarrow{AB}$$

- AB در جهت عمود بر مرز جداکننده
- اگر اندازهی بردار $AB=r$ در نظر گرفته شود، خواهیم داشت:



$$X = X_p + r \frac{W_{op}}{\|W_{op}\|}$$

$$\overrightarrow{AB} = r \frac{W_{op}}{\|W_{op}\|}$$



مرز جداسازی (ادامه...)

$$g(X) = W_{op}^T X + b_{op}$$

• داشتیم:

$$X = X_p + r \frac{W_{op}}{\|W_{op}\|}$$


$$g(X) = W_{op}^T \left[X_p + r \frac{W_{op}}{\|W_{op}\|} \right] + b_{op}$$

$$g(X) = \underbrace{W_{op}^T X_p + b_{op}}_{\text{روی مرز پس برابر با صفر}} + r \frac{W_{op}}{\|W_{op}\|} W_{op}^T$$

روی مرز پس برابر با صفر

$$g(X) = r \frac{\|W_{op}\|^2}{\|W_{op}\|}$$

$$g(X) = r \|W_{op}\|$$



$$g(X) = W_{op}^T X + b_{op}$$


$$g(X) = r \|W_{op}\|$$

$$r = \frac{g(X)}{\|W_{op}\|}$$

مرز جداسازی (ادامه...)


هدف ماکزیم نمودن r است.

در این حالت تمت شرایطی می‌باید W کمینه گردد.



$$X=0$$

$$r = \frac{g(X)}{\|W_{op}\|} = \frac{b_{op}}{\|W_{op}\|}$$



مثبت یا منفی بودن b_{op} نشان دهنده‌ی این است که مبدأ در کدام سمت خط مرزی است.

فاصله از مبدأ مختصات

مرز جداسازی (ادامه...)

ماتریس W_{op} و b_{op} است

• جداساز خطی را به صورت زیر در نظر می‌گیریم:

$$(X_i, +1) \quad W_{op}^T X_i + b_{op} \geq 1 \quad \text{for } d_i = +1$$

$$(X_i, -1) \quad W_{op}^T X_i + b_{op} \leq -1 \quad \text{for } d_i = -1$$


به صورت کلی داریم:

$$d_i (W_{op}^T X_i + b_{op}) \geq 1$$

• رابطه‌ی بالا برای تمامی الگوهای آموزشی برقرار است.

• و در نتیجه برای بردارهای پشتیبان

$$g(X^s) = W_{op}^T X^s + b_{op} = \pm 1$$




مرز جداسازی (ادامه...)

$$g(X^s) = W_{op}^T X^s + b_{op} = \pm 1$$


$$r = \frac{g(X^s)}{\|W_{op}\|} = \begin{cases} \frac{1}{\|W_{op}\|} \\ -\frac{1}{\|W_{op}\|} \end{cases}$$

• در نتیجه فاصله‌ی دو بردار پشتیبان در دو طرف مرز:

$$\rho = 2r = \frac{2}{\|W_{op}\|}$$




جدایی پذیر خطی



می دانیم:

- $W \cdot X^+ + b = +1$
- $W \cdot X^- + b = -1$
- $W \cdot (X^+ - X^-) = 2$



جدایی‌پذیر خطی

$$\rho = 2r = \frac{\|\pm 2\|}{\|W_{op}\|}$$

- با توجه به دو رابطه‌ی
- به این نتیجه می‌رسیم که W_{op} می‌باید مینیمم گردد.

- این مسئله معادل مینیمم کردن


$$\Phi(W) = \frac{1}{2} W^T W$$

– Φ یک تابع محدب (Convex Function) است.

– طبق رابطه‌ی $d_i(W_{op}^T X_i + b_{op}) \geq 1$ برای N الگوی آموزشی شروط زیر می‌باید برقرار باشد:

$$[d_i(W_{op}^T X_i + b_{op}) - 1] \geq 0$$


شرط توی برای برخی نمونه‌ها باید برقرار باشد یادگیری ماشین



وزن‌ها و بایاس را به گونه‌ای بیابید که:

$$\rho = \frac{2}{\|W\|} \text{ is maximized}$$

and for all $(X_i, d_i), i=1..N : d_i(W^T X_i + b) \geq 1$




وزن‌ها و بایاس را به گونه‌ای بیابید که:

$$\Phi(W) = 1/2 \|W\|^2 = 1/2 W^T W \text{ is minimized}$$

and for all $(X_i, d_i), i=1..N : d_i (W^T X_i + b) \geq 1$





یافتن بهینه

Lagrange multiplier

• از روش «ضرایب لاگرانژ» برای حل این مسأله‌ی بهینه‌سازی استفاده می‌شود:

– در این شیوه به تابع هدف اولیه قید مورد نظر را اضافه می‌کنیم.


– قید عبارتی است که همواره بزرگ‌تر یا مساوی صفر است.

$$J(W, b, \alpha) = \frac{1}{2} W^T W - \sum_{i=1}^N \alpha_i [d_i(W^T X_i + b) - 1]$$

به ازای هر نمونه یک قید داریم

• به سادگی می‌توان نشان داد که نقطه بهینه نقطه زینی این رابطه است:

$$\min_{W, b} \max_{\alpha \geq 0} J(W, b, \alpha)$$



$$\left\{ \begin{array}{l} \max Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i d_i \alpha_j d_j X_i^T X_j \\ \sum_{i=1}^N \alpha_i d_i = 0 \\ \alpha_i \geq 0 \text{ for } i = 0, 1, \dots, N \end{array} \right.$$

α_i ها وابسته به ضرب داخلی نمونه‌های آموزشی و خروجی‌های مرتبط است

$$W_{op} = \sum_{i=1}^N \alpha_i d_i X_i$$




Karush–Kuhn–Tucker(KKT) condition of optimization theory

• با توجه به شرط KKT خواهیم داشت:

$$\alpha_i = 0 \quad \longrightarrow \quad [d_i(W^T X_i + b) - 1] > 0$$

$$\alpha_i > 0 \quad \longrightarrow \quad [d_i(W^T X_i + b) - 1] = 0$$

• در نتیجه تنها α_i متناظر با بردارهای پشتیبان
غیرصفر خواهد بود.




یافتن رویه ی بهینه

- پس از به دست آوردن α خواهیم داشت:

$$W_{op} = \sum_{i=1}^N \alpha_i d_i X_i$$

$$X^s = X^{\text{support vector}} \quad \longrightarrow \quad W_{op}^T X^s + b_{op} = \pm 1$$

$$\longrightarrow \quad b_{op} = \pm 1 - W_{op}^T X^s$$



یافتن رویه بهینه

$$W = \sum \alpha_i d_i X_i \quad b = d_k - W^T X_k \text{ for any } X_k \text{ such that } \alpha_k \neq 0$$


هر α_i مخالف صفر، نشان‌دهنده‌ی این است که X_i متناظرش یک بردار پشتیبان است.
در این حالت تابع جداکننده همانند زیر است:

$$g(X) = \sum \alpha_i d_i \underbrace{X_i^T X}_{} + b$$

ضرب داخلی دو بردار



توجه:

حل مساله بهینه‌سازی وابسته به محاسبه ضرب داخلی بین تمامی نمونه‌های آموزشی است.



Soft Margin

- SVM برای داده‌های **جدایی‌پذیر خطی** مورد بررسی قرار گرفت.
- حال اگر مجموعه‌ی داده‌های آموزش قابلیت جداسازی خطی نداشته باشد، چه خواهد شد؟ به بیان بهتر صحبت در مورد مسائل جدایی‌پذیر است که با نویز همراه هستند.




Soft Margin

- مسأله‌ی **Hard Margin** را تبدیل به حل مسأله‌ی **Soft Margin** می‌شود.

- ماشیهی جداسازی soft گفته می‌شود، در صورتی که برای برخی داده‌ها شرط زیر نقض شود:

$$d_i(W_{op}^T X + b_{op}) \geq 1$$




- با اضافه کردن یک **Slack Variable**

مسأله را بار دیگر بررسی می‌کنیم.


- این متغیر میزان انحراف از شرط فوق را نشان می‌دهد.

$$d_i(W_{op}^T X_i + b_{op}) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N$$




Soft Margin Classification

$$0 \leq \xi_i \leq 1$$




$$\xi_i > 1$$



- دو حالت ممکن است رخ دهد:
- داده‌ی در کلاس درست ولی در حاشیه قرار گیرد.
- داده‌ی آموزشی به اشتباه دسته‌بندی شود.

$$d_i(W_{op}^T X_i + b_{op}) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N$$



Soft Margin Classification


$$d_i(\mathbf{W}_{op}^T \mathbf{X} + b_{op}) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N$$

- در این حالت بردارهای پشتیبان آن‌هایی هستند که در رابطه‌ی تساوی در عبارت بالا صدق می‌کنند، حتی با وجود $\xi > 0$

– در صورتی که داده‌های نویزی از مجموعه خارج شود، رویه‌ی جداکننده تخییر خواهد کرد.

- هدف یافتن «رویه‌ای جداکننده با بیشترین ماشیه» است که خطای دسته‌بندی نادرست در آن مینیمم شود:

$$\Phi(\xi) = \sum_{i=1}^N I(\xi_i - 1) \quad I(\xi) = \begin{cases} 0 & \text{if } \xi \leq 0 \\ 1 & \text{if } \xi > 0 \end{cases}$$



Soft Margin Classification

- با توجه به این که کمینه کردن چنین تابعی یک مسأله‌ی بهینه‌سازی **nonconvex** است و در رده‌ی NP-complete قرار می‌گیرد، آن را با تابع زیر تقریب می‌زنیم:

$$\Phi(\xi) = \sum_{i=1}^N \xi_i$$

- و در کل هدف می‌نیمیم کردن عبارت زیر است:


$$\Phi(W, \xi) = \frac{1}{2} W^T W + C \sum_{k=1}^R \varepsilon_k$$

regularization parameter

این پارامتر نوعی مصالحه بین پیچیدگی ماشین و خطا برقرار می‌کند. هرچه C بزرگتر شود، نزدیک‌تر باشد به این معناست که خطا اهمیت کم‌تری دارد و در نتیجه ضرایب بزرگ‌تر می‌شود. و هرچه بزرگ‌تر باشد، ما به حالت **hard margin** نزدیک‌تر می‌شویم.




مثال



Large value for C

Small value for C



Soft Margin

- برای Hard Margin داشتیم:

Find W and b such that
 $\Phi(W) = \frac{1}{2} W^T W$ is minimized and for all $\{(X_i, d_i)\}$
 $d_i (W^T X_i + b) \geq 1$

- با اضافه کردن Slack Variable داریم:

Find W and b such that
 $\Phi(W) = \frac{1}{2} W^T W + C \sum \xi_i$ is minimized and for all $\{(X_i, d_i)\}$
 $d_i (W^T X_i + b) \geq 1 - \xi_i$ and $\xi_i \geq 0$ for all i



یافتن رویه‌ی بهینه


- رابطه‌ی لاگرانژ زیر تعریف می‌شود به گونه‌ای که همه‌ی نیازمندی‌ها را پوشش دهد:

$$J(W, b, \xi, \alpha, \mu) = \frac{1}{2} W^T W + C \sum_i \xi_i - \sum_{i=1}^N \alpha_i [d_i (W^T X_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i$$

– بخش آخر از این رو اضافه شده است که تا نامنفی بودن ξ را تضمین کند.

- حل این بهینه‌سازی معادل حل مساله‌ی زیر است:

$$\min_{W, b, \varepsilon} \max_{\alpha, \mu \geq 0} J(W, b, \xi, \alpha, \mu)$$



Soft Margin Classification

در نهایت ضرایب لاگراثر از عبارت زیر محاسبه خواهند شد:

$$\max_{\alpha \geq 0} Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j X_i^T X_j$$


با در نظر گرفتن قیود زیر

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

بقیه مراحل مانند حالت قبل خواهد بود:

$$W_{op} = \sum_{i=1}^{N_s} \alpha_i d_i X_i$$



Quadratic programming

- QP فرآیند یافتن بردار x است به گونه‌ای که تابع هدف به کمترین مقدار خود برسد:

$$\min_x \frac{1}{2} \mathbf{x}^T H \mathbf{x} + \mathbf{c}^T \mathbf{x}$$

```
for k1 in range(n):  
    for k2 in range(n):  
        H[k1, k2] = d[k1] * d[k2] * np.dot(X[:, k1], X[:, k2])
```

```
def objective(alpha):  
    return 0.5 * np.dot(alpha, np.dot(H, alpha)) - np.sum(alpha)
```


$$A\mathbf{x} \leq b$$

$$l \leq \mathbf{x} \leq u$$



$$A_{eq}\mathbf{x} = b_{eq}$$

- و شروط زیر برقرار باشد:

```
lb = np.zeros(n)  
ub = C * np.ones(n)  
def eq_constraint(alpha):  
    return np.dot(alpha, d)
```



مثال (ادامه...)





```
lb = np.zeros(n)
ub = C * np.ones(n)
# Define the objective function for optimization
def objective(alpha):
    return 0.5 * np.dot(alpha, np.dot(H, alpha)) - np.sum(alpha)
# Equality and bounds constraints
def eq_constraint(alpha):
    return np.dot(alpha, d)

constraints = ({'type': 'eq', 'fun': eq_constraint})
bounds = [(lb[i], ub[i]) for i in range(n)]


# Solve quadratic programming problem
result = minimize(objective, np.zeros(n), method='SLSQP', bounds=bounds,
constraints=constraints)
alpha = result.x
```






SVM غیرخطی



- برای داده‌هایی که قابلیت جداسازی خطی دارند، عملکرد سیستم بسیار خوب است.



- اگر داده‌ها به صورت‌های زیر باشد، مسأله چگونه حل می‌شود؟




نگاشت به یک فضای *High Dimension*






نگاشت به فضای بالاتر

- همواره فضای ورودی می‌تواند به فضایی با ابعاد بالاتر نگاشت گردد.
- این نگاشت می‌تواند به صورتی باشد که در این فضای جدید ورودی‌ها قابلیت جداسازی داشته باشند.




$$\Phi: X \rightarrow \phi(X)$$



دانشگاه
تهران

نگاشت به فضای بالاتر




$$W^T X + b = 0$$

- هنگامی که ورودی‌ها به فضای دیگری نگاشت شوند، برای نگاشت جدید خواهیم داشت:

$$\Phi(X) = [\varphi_1(X), \varphi_2(X), \dots, \varphi_{m_1}(X)]^T$$

- در این حالت هدف یافتن رویه‌ی جداسازی است به‌گونه‌ای که:

$$\sum_{j=1}^{m_1} w_j \varphi_j(X) + b = 0$$




نگاشت به فضای بالاتر

$$\sum_{j=1}^{m1} w_j \varphi_j(X) + b = 0$$

• با فرض $\varphi_0(X) = 1$

• خواهیم داشت:


$$\sum_{j=0}^{m1} w_j \varphi_j(X) = 0$$



$$W^T \Phi(X) = 0$$

$$\Phi(X) = [1, \Phi(X)]^T$$

$$W = [b = w_0, w_1, w_2, \dots, w_{m1}]^T$$



نگاشت به فضای بالاتر


- در این مرحله تمامی شروط و قیودی که برای جداسازی خطی در نظر گرفتیم وجود دارد تنها به جای X_i ها $\Phi(X_i)$ در نظر گرفته می‌شود:

$$d_i \left(\sum_{j=0}^{m_1} w_j \varphi_j(X_i) - 1 \right) \geq 0$$

$$W_{opt} = \sum_{i=1}^N \alpha_i \cdot d_i(\Phi(X_i))$$



$$W_{opt}^T \Phi(X) = 0 \quad \Rightarrow \quad \sum_{i=1}^N \alpha_i \cdot d_i \Phi^T(X_i) \Phi(X) = 0$$



نگاشت به فضای بالاتر


$$\sum_{i=1}^N \alpha_i \cdot d_i \Phi^T(X_i) \Phi(X) = 0$$

$$K(X_i, X_j) = \varphi(X_i)^T \varphi(X_j)$$

$$\sum_{i=1}^N \alpha_i \cdot d_i K(X_i, X) = 0$$

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j K(X_i, X_j)$$

تابع kernel، تابعی است که معادل ضرب داخلی دو بردار
خصیصه است.



$$\mathbf{x}=[x_1 \ x_2]^T;$$

$$K(\mathbf{x}_i, \mathbf{x}_j)=(1 + \mathbf{x}_i^T \mathbf{x}_j)^2,$$

$$\begin{aligned} K(\mathbf{x}_i, \mathbf{x}_j) &= (1 + \mathbf{x}_i^T \mathbf{x}_j)^2 = 1 + x_{i1}^2 x_{j1}^2 + 2 x_{i1} x_{j1} x_{i2} x_{j2} + x_{i2}^2 x_{j2}^2 + 2 x_{i1} x_{j1} + 2 x_{i2} x_{j2} \\ &= [1 \ x_{i1}^2 \ \sqrt{2} x_{i1} x_{i2} \ x_{i2}^2 \ \sqrt{2} x_{i1} \ \sqrt{2} x_{i2}]^T [1 \ x_{j1}^2 \ \sqrt{2} x_{j1} x_{j2} \ x_{j2}^2 \ \sqrt{2} x_{j1} \ \sqrt{2} x_{j2}] \\ &= \boldsymbol{\phi}(\mathbf{x}_i)^T \boldsymbol{\phi}(\mathbf{x}_j), \end{aligned}$$


$$\Rightarrow K(\mathbf{x}_i, \mathbf{x}_j) = \boldsymbol{\phi}(\mathbf{x}_i)^T \boldsymbol{\phi}(\mathbf{x}_j):$$

$$\text{where } \boldsymbol{\phi}(X) = [1 \ x_1^2 \ \sqrt{2} x_1 x_2 \ x_2^2 \ \sqrt{2} x_1 \ \sqrt{2} x_2]$$

Mercer's theorem:

Every semi-positive definite symmetric function is a kernel

$K(X_1, X_1)$	$K(X_1, X_2)$	$K(X_1, X_3)$	...	$K(X_1, X_n)$
$K(X_2, X_1)$	$K(X_2, X_2)$	$K(X_2, X_3)$		$K(X_2, X_n)$
...	...	...	...	...
$K(X_n, X_1)$	$K(X_n, X_2)$	$K(X_n, X_3)$	...	$K(X_n, X_n)$



نگاشت به فضای بالاتر

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \underbrace{\Phi(X_i) \Phi(X_j)}_{K(X_i, X_j)}$$

$$K_{N \times N} = \left\{ K(X_i, X_j) \right\}_{i,j=1}^N$$

$$K(X_i, X_j)$$

ماتریس مقارن

هدف یافتن ضرایب لاگراش بیشینه در عبارت زیر است:

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j K(X_i, X_j)$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

با در نظر گرفتن قیود زیر

$$0 \leq \alpha \leq C$$

kernel trick

در صورت یافتن تابع kernel مناسب بدون این که درگیر مشکلات فضای با ابعاد بالا (نکبت ابعاد) شویم، تنها از نتیجه این نگاشت بهره می‌بریم.



$$g(X) = \sum \alpha_i d_i K(X_i, X)$$

کرنل‌های معمول

$$k(\mathbf{x}, \mathbf{x}_i)$$

$$i = 1, 2, \dots, N$$

polynomial

$$(\mathbf{x}^T \mathbf{x}_i + 1)^p$$

RBF


$$\exp\left(-\frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{x}_i\|^2\right)$$



tanh


$$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$$



chi-squared kernel

$$1 - \sum_{i=1}^n \frac{(\mathbf{x} - \mathbf{x}_i)}{\frac{1}{2}(\mathbf{x} + \mathbf{x}_i)^2}$$









ساخت کرنل‌های جدید

- براساس کرنل‌های موجود به سادگی می‌توان کرنل‌های جدید ساخت:


– هر تابع $K(.,.)$ یک کرنل است چنانچه معادل ضرب داخلی بردارهای حاصل از نگاشت باشد.

جمع دو کرنل

$$K(x, y) = c_1 K_1(x, y) + c_2 K_2(x, y) \quad c_1, c_2 \geq 0$$

$$\phi(x) = (\sqrt{c_1} \phi_1(x), \sqrt{c_2} \phi_2(x))$$

$$\phi(x) \cdot \phi(y) = c_1 \phi_1(x) \cdot \phi_1(y) + c_2 \phi_2(x) \cdot \phi_2(y)$$




مواجهه با مجموعه داده‌های نامتوازن

imbalanced Data

- در اکثر شیوه‌های یادگیری دسته، هنگامی که کلاس‌ها **نامتوازن** باشند، سوگیری به سمت دسته با داده بیشتر خواهیم داشت.
- ماشین بردار پشتیبان نیز از این قاعده مستثنی نیست.


– برای این که ماشین بردار پشتیبان در این شرایط خوب عمل کند، چه پیشنهادی دارید؟

از نوعی وزن دهی استفاده می‌شود. مقدار پارامتر منظم‌سازی برای کلاسی که تعداد نمونه کم‌تری دارد بیشتر در نظر گرفته می‌شود.




رگرسیون خطی

کدامیک از این خطوط داده‌ها را بهتر
مدل می‌کنند؟




$$g(x|W, b) = W^T x + b$$



تابع خطا


چه تابعی برای محاسبه
خطا مناسب است؟




$$err_i = (W^T X_i + b - r_i)^2$$


$$err_i = |W^T X_i + b - r_i|$$

کدامیک نسبت به
داده‌های دورافتاده
مقاوم‌تر هستند؟






$$err_i = (W^T X_i + b - r_i)^2$$




$$err_i = |W^T X_i + b - r_i|$$

برای این که نسبت به بیش‌برازش حساسیت کم‌تری داشته باشیم، پیشنهادی دارید؟




ϵ -sensitive(hing) Loss

$$E(\theta | \mathcal{X}) = \frac{1}{2} \sum_{t=1}^N 1(|r^t - g(x^t | \theta)| > \epsilon) (|r^t - g(x^t | \theta)| - \epsilon)$$




Yıldız, Olcay Taner, and Ethem Alpaydın. "Statistical Tests Using Hinge/E-Sensitive Loss." In *Computer and Information Sciences iii*, 153-60: Springer, 2013.



Support Vector regression(SVR)

$$(W^T X_i + b) - r_i \leq \varepsilon$$

$$\frac{1}{2} W^T W \rightarrow \text{minimize}$$



http://www.saedsayad.com/support_vector_machine_reg.htm

